Universidade do Minho
Escola de Engenharia
Licenciatura em Engenharia Informática

Resolução de Problemas
Algoritmos de procura

Ano Letivo de 2024/2025

Inteligência Artificial

Tiago Alves
A106883

Nuno Fernandes
A107317

Salomé Faria
A108487

Pedro Esteves
A106839

January 11, 2026

IA

1. Avaliação pelos Pares

Distribuição do esforço e contribuição de cada membro do grupo para a realização deste trabalho.

Nome	Número	Delta
Tiago Alves	A106883	0
Nuno Fernandes	A107317	0
Salomé Faria	A108487	0
Pedro Esteves	A106839	0

Tabela 1: Distribuição de Deltas

Índice

1. Avaliação pelos Pares **2**

2. Introdução **1**
2.1. Objetivos 1

3. Descrição do Problema **1**

4. Formulação do Problema **2**
4.1. Representação do Estado 2
4.1.1. Estado Inicial (S_0) 3
4.1.2. Estado Objetivo (S^*) 3
4.2. Operadores e Dinâmica de Execução 3
4.2.1. Operadores de Vizinhança 3
4.2.2. Transições Automáticas do Ambiente 4
4.2.3. Reavaliação Contínua 4
4.3. Função de Custo 4
4.3.1. Custo de Atribuição Individual 4
4.3.2. Penalização da Fila de Espera 5
4.3.3. Restrições de Viabilidade 5

5. Modelação e Implementação **5**
5.1. Ambiente de Simulação 5
5.1.1. Grafo de Navegação 5
5.1.2. Trânsito Dinâmico 6
5.1.3. Sistema Meteorológico 6
5.1.4. Hotspots (Zonas de Alta Densidade) 6
5.1.5. Falhas de Infraestrutura 7
5.2. Agentes (Veículos) 8
5.2.1. Gestão de Bateria/Combustível 8
5.3. Características dos Pedidos 8
5.3.1. Taxa de Chegada (Processo de Poisson) 8
5.3.2. Atributos dos Pedidos 9

6. Algoritmos Desenvolvidos **9**
6.1. Subproblema de Procura de Caminho 9
6.1.1. Algoritmos Implementados 10
6.1.2. Comparação dos Algoritmos de Procura 10
6.2. Algoritmos de Atribuição (Assignment) 11
6.2.1. Simulated Annealing — Parâmetros 11
6.2.2. Justificação das Escolhas de Design 11
6.3. Otimização da Atribuição de Pedidos 12
6.3.1. Pipeline de Atribuição 12
6.3.2. Otimizações Implementadas 13

7. Reprodutibilidade e Determinismo **14**
7.1. Componentes com Seed Fixa 14
7.2. Processos Estocásticos 14

7.3. Exceção . . . 14
8. Metodologia de Testes e Resultados . . . 15
8.1. Configuração Experimental . . . 15
8.2. Métricas de Avaliação . . . 15
8.3. Resultados Globais . . . 15
8.4. Análise Detalhada . . . 16
8.4.1. Impacto do Algoritmo de Routing . . . 16
8.4.2. Impacto do Algoritmo de Atribuição . . . 16
8.4.3. Tempo Médio de Resposta ao Pedido . . . 17
8.4.4. Taxa de Pedidos Não Atendidos . . . 17
8.4.5. Emissões de CO2 . . . 18
8.4.6. Taxa de Ocupação da Frota . . . 18
8.4.7. Km Percorridos Sem Passageiros . . . 19
8.5. Síntese dos Resultados . . . 19
9. Correspondência com as Tarefas Pedidas . . . 20
9.1. Funcionalidades Extra Implementadas . . . 20
10. Conclusão e Reflexão . . . 21
10.1. Resposta aos Desafios do Enunciado . . . 21
11. Apresentação da Interface . . . 22
12. Referências . . . 22
Anexos . . . 23
12.1. Anexo A: Galeria da Interface . . . 23
12.1.1. Controlos e Ambiente . . . 23
12.1.2. Gestão de Pedidos . . . 24
12.1.3. Infraestrutura e Veículos . . . 25
12.1.4. Visualização de Dados . . . 25
12.2. Anexo B: Especificações da Frota . . . 26
12.3. Anexo C: Dados Completos de Benchmark . . . 26
12.3.1. Métricas Financeiras . . . 27
12.3.2. Métricas Operacionais . . . 27
12.3.3. Métricas de Quilometragem . . . 28
12.3.4. Métricas Ambientais e de Frota . . . 28
12.3.5. Tempo em Estações de Recarga . . . 28

Lista de Figuras

Figura 1 Grafo da cidade de Braga (obtido através do OSMnx) . . . 5
Figura 2 Visualização das camadas de trânsito (Perlin Noise) . . . 6
Figura 3 Distribuição dos Hotspots na cidade de Braga . . . 7
Figura 4 Visualização de uma estação de serviço inoperacional . . . 7
Figura 5 Gestão da Frota: Monitorização de estatísticas individuais . . . 8
Figura 6 Seleção do algoritmo de procura de caminho . . . 10
Figura 7 Seleção do algoritmo de atribuições . . . 13

Figura 8 Gráfico de métricas temporais: Espera vs. Viagem 17
Figura 9 Análise do Impacto Ambiental (Emissões CO2) 18
Figura 10 Visualização do mapa com veículos e pedidos em tempo real e Painel lateral com métricas de desempenho (lucro, CO2, tempos de espera) 22
Figura 11 Painel de Controlo da Simulação 23
Figura 12 Ciclo Dia/Noite na Interface 23
Figura 13 Painel de Controlos dos algoritmos, velocidade de simulação e benchmark 24
Figura 14 Lista de Pedidos Ativos 24
Figura 15 Visualização de Destino no Mapa 24
Figura 16 Pedido Pendente (Azul) 24
Figura 17 Pedido Atribuído (Verde) 24
Figura 18 Posto de Abastecimento 25
Figura 19 Posto de Carregamento EV 25
Figura 20 Posto de Abastecimento e Carregamento EV 25
Figura 21 Visualização do Processo de Otimização 25
Figura 22 Painel de Métricas em Tempo Real 25
Figura 23 Hotspot Ativo (Alta Procura) 26
Figura 24 Hotspot Inativo 26

Lista de Tabelas

Tabela 1 Distribuição de Deltas 2
Tabela 2 Operadores de Vizinhança 3
Tabela 3 Transições Automáticas do Ambiente 4
Tabela 4 Componentes da Função de Custo de Atribuição 4
Tabela 5 Taxa de Chegada de Pedidos por Período 8
Tabela 6 Detalhes dos Atributos dos Pedidos de Transporte 9
Tabela 7 Algoritmos de Procura de Caminho Implementados 10
Tabela 8 Somas das Métricas de Procura (100 rotas de teste) 10
Tabela 9 Algoritmos de Atribuição Implementados 11
Tabela 10 Otimizações Implementadas no Sistema de Atribuição 13
Tabela 11 Seeds Fixas para Reprodutibilidade 14
Tabela 12 Configuração do Ambiente de Benchmark 15
Tabela 13 Métricas Recolhidas por Cada Simulação 15
Tabela 14 Resultados das 9 Combinações de Algoritmos 16
Tabela 15 Métricas Financeiras por Algoritmo de Routing 16
Tabela 16 Comparação dos Algoritmos de Atribuição 16
Tabela 17 Taxa de Sucesso (Pedidos Atendidos) 17
Tabela 18 Taxa de Ocupação da Frota 18
Tabela 19 Km Percorridos Sem Passageiros 19
Tabela 20 Resumo: Melhor Combinação por Objetivo 19
Tabela 21 Correspondência Tarefa-Implementação 20
Tabela 22 Comparação detalhada entre Tipos de Veículos 26
Tabela 23 Benchmark — Métricas Financeiras Completas 27
Tabela 24 Benchmark — Métricas Operacionais Completas 27

Tabela 25 Benchmark — Métricas de Quilometragem Completas 28
Tabela 26 Benchmark — Métricas Ambientais e de Frota 28
Tabela 27 Benchmark — Tempo Total em Estações de Recarga/Abastecimento 28

2. Introdução

Este relatório apresenta as informações relativas ao projeto da Unidade Curricular de Inteligência Artificial, pertencente ao 3º Ano da Licenciatura em Engenharia Informática, realizada no ano letivo 2025/2026, na Universidade do Minho.

O objetivo foi desenvolver algoritmos de procura que permitam otimizar a gestão de uma frota de táxis heterogénea, composta por veículos a combustão e elétricos, garantindo a eficiência operacional, a redução de custos energéticos e o cumprimento de critérios ambientais.

A solução implementada utiliza algoritmos lecionados na cadeira de Inteligência Artificial, nomeadamente algoritmos de procura informada e algoritmos de otimização local para resolver o problema de atribuição de veículos e pedidos em tempo real.

2.1. Objetivos

O objetivo principal é desenvolver e comparar algoritmos de procura e otimização para:

- Maximizar o lucro operacional (Receita - Custos).
- Minimizar o tempo de espera dos clientes.
- Garantir a sustentabilidade ambiental (redução de CO2).
- Gerir eficazmente as restrições de autonomia dos veículos elétricos (EVs).

3. Descrição do Problema

A **TaxiGreen** é uma empresa moderna de transporte urbano que enfrenta um desafio complexo: gerir uma frota mista de veículos (elétricos e a combustão) numa cidade movimentada como Braga. O objetivo não é apenas levar passageiros do ponto A ao ponto B, mas fazê-lo da forma mais eficiente e sustentável.

Pedidos de transporte são requisitados consoante a hora do dia, com origem e destino em diferentes partes da cidade. Podem requisitar ser atendidos rapidamente, como também optar por uma viagem ecológica. A empresa tem à sua disposição carros elétricos (baratos de operar, mas com autonomia limitada e recarga demorada) e carros a combustão (rápidos de abastecer, mas caros e poluentes).

O nosso trabalho é criar um programa para gerir esta operação. Um sistema inteligente que decide, em tempo real:

1. Que veículo deve atender qual pedido?
2. Qual o melhor caminho para lá chegar, fugindo ao trânsito?
3. Quando é que um carro elétrico deve parar para carregar antes que fique sem bateria?

Para resolver isto, transformamos a cidade num Grafo (uma rede de nós e arestas) obtido através do *OSMnx* e utilizamos algoritmos de Inteligência Artificial para encontrar as melhores soluções de rota e atribuição.

4. Formulação do Problema

Para responder ao desafio de gestão de frota da TaxiGreen, o problema foi modelado como um problema de Otimização Combinatória resolvido através de pesquisa local.

Ao contrário de um problema de navegação simples, o desafio aqui não é encontrar apenas um caminho, mas sim encontrar a configuração de alocação ótima entre veículos e pedidos num determinado instante, considerando restrições de capacidade e autonomia.

A formulação segue a estrutura clássica de um problema de procura:

- **Estado**: Representação do sistema num dado instante
- **Operadores**: Ações que modificam o estado
- **Função de Custo**: Critério de otimização

Tipo de problema: O problema da TaxiGreen classifica-se como um problema de otimização combinatória num ambiente dinâmico e estocástico.

- **Combinatório**: Com N veículos e M pedidos, existem $(M+1)^N$ configurações possíveis.
- **Dinâmico**: O ambiente muda independentemente das ações do agente. Aparecem novos pedidos, o trânsito varia, as estações falham e a meteorologia evolui ao longo do tempo.
- **Estocástico**: Os processos que manipulam o ambiente são probabilísticos:
  - Chegada de pedidos: Processo de Poisson não-homogéneo com taxa $\lambda(t)$ variável
  - Trânsito: Ruído de Perlin 3D para variabilidade espacial e temporal orgânica
  - Meteorologia: Ruído de Perlin 1D para transições suaves entre estados
  - Falhas de infraestrutura: Probabilidade de 0.01% por tick de simulação
  - Atributos de pedidos: Prioridade, passageiros e preferências gerados aleatoriamente
- **Parcialmente Observável**: O futuro (novos pedidos, evolução do trânsito) é desconhecido no momento da decisão, exigindo planeamento adaptativo.

4.1. Representação do Estado

O sistema possui um estado S_t num instante t, definido como um tuplo $S_t = (A, B, V)$:

- **A (Atribuições)**: Mapeamento $V \to R \cup \{\emptyset\}$, cada veículo está livre ou atribuído a um pedido
- **B (Fila de Espera)**: Conjunto de pedidos pendentes ainda não atribuídos nem recolhidos por nenhum veículo
- **V (Estado Projetado)**: Para cada veículo, a posição, autonomia e tempo estimados após completar a tarefa atual

Esta representação permite avaliar não só o custo imediato, mas também a viabilidade futura (ex: evitar atribuições que deixariam um veículo sem autonomia).

4.1.1. Estado Inicial (S_0)

No arranque da simulação:

- **Atribuições**: $\forall v \in V : A[v] = \emptyset$, todos os veículos livres
- **Fila**: $B = \emptyset$, sem pedidos pendentes
- **Posições**: Veículos colocados em posições aleatórias (seed 42)
- **Autonomia**: Combustão 600-900 km; Elétricos 200-420 km
- **Tempo**: $t_0 =$ 00:00 do primeiro dia

Formalmente: $S_0 = \left(\{v_i \to \emptyset\}_{i=1}^{n}, \emptyset, \{\text{pos}, \text{autonomia}, \text{tempo} : t_0\}\right)$

4.1.2. Estado Objetivo (S^*)

Este é um **problema de otimização contínua e dinâmica** — não existe um estado final discreto. O objetivo é a **minimização contínua** da função de energia:

$$S^* = \arg\min E(S) \quad \forall t$$

Características:

1. **Sem Fim**: O sistema processa pedidos indefinidamente
2. **Ótimo Local vs. Global**: Decisões locais podem não ser globalmente ótimas
3. **Restrições de Validade**: Autonomia ≥ 0, capacidade respeitada, fila minimizada
4. **Critério Prático**: Falhas < 15%, espera < 15 min, lucro positivo

4.2. Operadores e Dinâmica de Execução

As ações que modificam o estado dividem-se em operadores de vizinhança (controlados pelo algoritmo) e transições automáticas (eventos do ambiente).

4.2.1. Operadores de Vizinhança

Cinco operadores para gerar estados vizinhos S':

Operador	Descrição
Assign(v, r)	Atribui pedido r da fila ao veículo livre v
Unassign(v)	Remove atribuição, devolvendo pedido à fila
Swap(v_1, v_2)	Troca pedidos entre dois veículos
Move(v_src, v_dst)	Move pedido de veículo ocupado para livre
Replace(v, r_new)	Substitui pedido atual por outro da fila

Tabela 2: Operadores de Vizinhança

4.2.2. Transições Automáticas do Ambiente

Evento	Efeito
Timeout(r)	Remove pedido expirado da fila
CompleteTrip(v)	Liberta veículo após entrega
StartRecharge(v)	Envia veículo para estação (indisponível)
CompleteRecharge(v)	Restaura autonomia e disponibilidade
NewRequest(r)	Adiciona pedido à fila, força reavaliação

Tabela 3: Transições Automáticas do Ambiente

4.2.3. Reavaliação Contínua

O sistema opera com planeamento contínuo, reiniciando a procura quando:

- Chega um novo pedido
- Um veículo fica disponível (termina viagem ou recarga)
- Ocorre timeout de pedido

Isto permite reatribuir pedidos dinamicamente se surgir uma configuração de menor custo.

4.3. Função de Custo

O Teste Objetivo é a **minimização** da Função de Energia $E(S)$:

$$E(S) = \sum_{v \in \text{ Frota}} C(v, A[v]) + \sum_{r \in \text{ Fila}} C_{\text{espera}(r)} + P_{\text{viabilidade}}$$

4.3.1. Custo de Atribuição Individual

O custo de atribuir veículo v a pedido r é:

$$C(v, r) = C_{\text{tempo}} + C_{\text{espera}} + C_{\text{ambiente}} + C_{\text{capacidade}} + C_{\text{bateria}} + C_{\text{logística}} + C_{\text{oportunidade}} + C_{\text{lucro}}$$

Componente	Descrição	Peso
C_{tempo}	Tempo de viagem até ao cliente (via A*)	1.0
C_{espera}	Bónus negativo por tempo de espera e prioridade	4.0 / 30.0
C_{ambiente}	Penalização se combustão atende pedido ecológico	15.0/km
$C_{\text{capacidade}}$	Penalização por lugares não utilizados	0.5/lugar
C_{bateria}	Risco se autonomia < 30km	20.0
$C_{\text{logística}}$	Distância a postos e hotspots após entrega	0.5 / 1.0
$C_{\text{oportunidade}}$	EVs em pedidos não-eco com pedidos eco na fila	50.0
C_{lucro}	Ajuste baseado no lucro projetado	10.0

Tabela 4: Componentes da Função de Custo de Atribuição

4.3.2. Penalização da Fila de Espera

$$C_{\text{espera}(r)} = 160 + (\text{Prio}^2 \times 30) + (\text{Age} \times 8)$$

O termo quadrático garante que VIPs (prio 5) custam 25× mais que normais (prio 1).

4.3.3. Restrições de Viabilidade

Um estado é inválido ($P_{\text{viabilidade}} = \infty$) se:

- Autonomia final < 0 para qualquer veículo
- Capacidade de passageiros insuficiente
- Impossibilidade de chegar a posto após entrega

5. Modelação e Implementação

5.1. Ambiente de Simulação

Utilizamos um mapa real da cidade de Braga obtido via `OSMnx` e serializado em `braga_map_cache.pkl`.

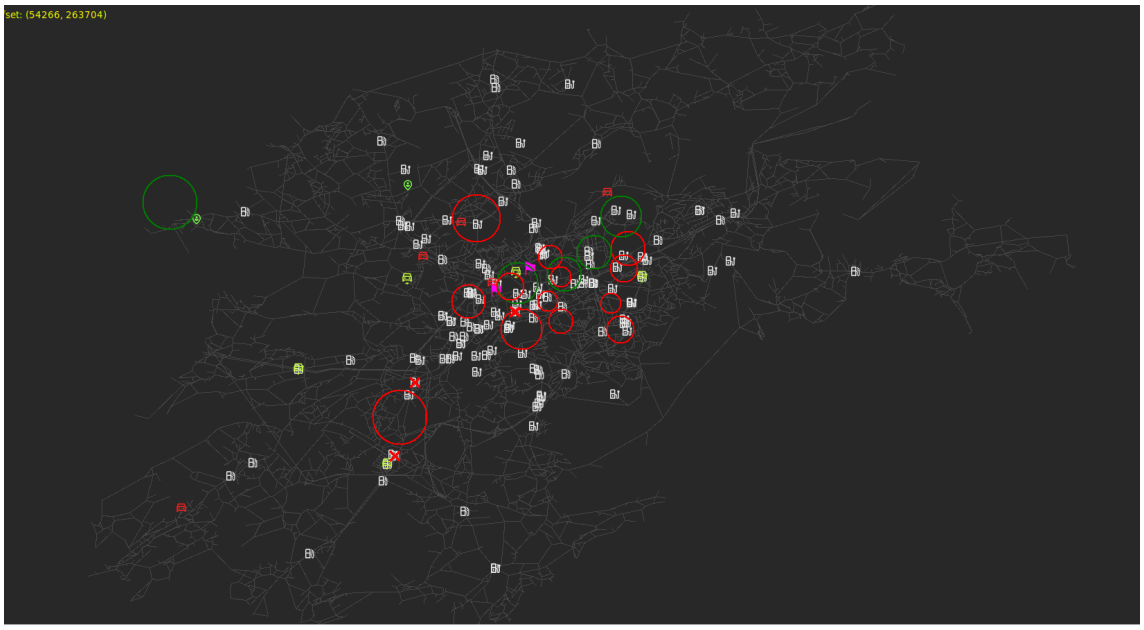

Figura 1: Grafo da cidade de Braga (obtido através do OSMnx)

5.1.1. Grafo de Navegação

Os nós representam intersecções e as arestas segmentos de estrada. As distâncias são calculadas via fórmula de Haversine (distância na esfera terrestre), permitindo navegação precisa no ambiente urbano.

5.1.2. Trânsito Dinâmico

O `TrafficManager` simula o fluxo de tráfego utilizando uma combinação sofisticada de:

- Curvas Gaussianas: Para modelar picos de hora de ponta:
  - Manhã (08:30): intensidade 0.6, largura 1.5
  - Almoço (13:00): intensidade 0.2, largura 1.2
  - Tarde (18:00): intensidade 0.8, largura 1.8 (pico máximo)
  - Noite (21:00): intensidade 0.1, largura 1.5
  - Base: 0.1
- Fórmula de Ganho Linear: $\text{gain} = \text{rush_intensity} \times 5.0$
  - Esta formulação aumenta o trânsito proporcionalmente à intensidade de pico
  - Durante picos, intensidade 0.8 → ganho ≈ 4.0
- Ruído de Perlin (3D): Para introduzir variabilidade espacial e temporal orgânica, evitando padrões repetitivos. O ruído é aplicado nas coordenadas (x, y, t) onde x e y são coordenadas geográficas e t é o tempo simulado.

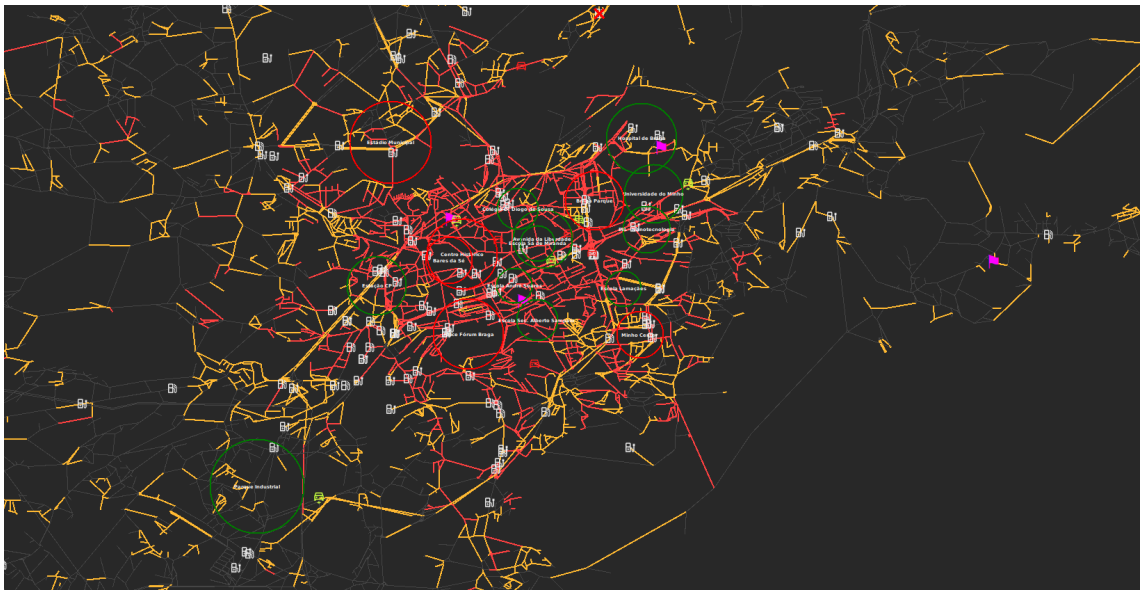

Figura 2: Visualização das camadas de trânsito (Perlin Noise)

5.1.3. Sistema Meteorológico

O clima é simulado através de Ruído de Perlin 1D sobre o tempo, garantindo transições suaves:

- Sol (noise < 0.45): penalização 1.0× (sem impacto)
- Nublado (noise 0.45-0.65): penalização 1.0× (sem impacto)
- Chuva (noise 0.65-0.85): penalização 1.3×
- Tempestade (noise > 0.85): penalização 1.6×

O valor de **noise** é normalizado para [0, 1] a partir do output do Perlin.

5.1.4. Hotspots (Zonas de Alta Densidade)

A distribuição de pedidos não é uniforme. Implementamos um sistema de 18 Hotspots que modela zonas de alta procura na cidade de Braga:

Principais Hotspots (por categoria)::

- **Educação**: Universidade do Minho, Escola Sá de Miranda, Colégio D. Diogo de Sousa
- **Transportes**: Estação CP
- **Comercial**: Braga Parque, Nova Arcada, Minho Center
- **Saúde**: Hospital de Braga
- **Lazer**: Centro Histórico, Bares da Sé, Altice Fórum, Estádio Municipal
- **Tecnologia**: INL - Nanotecnologia
- **Industrial**: Parque Industrial

Este sistema garante que os pedidos se concentram em zonas realistas (universidades de manhã, bares à noite, hospital 24h, etc.).

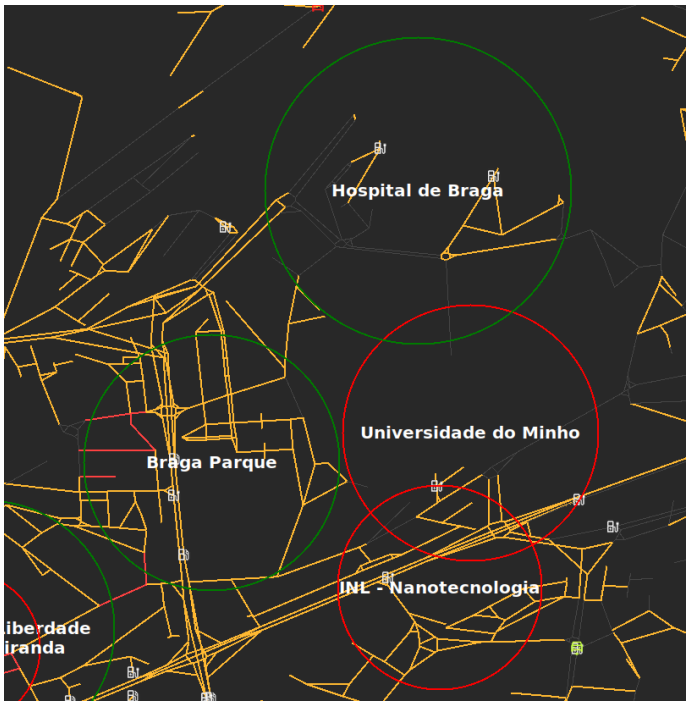

Figura 3: Distribuição dos Hotspots na cidade de Braga

5.1.5. Falhas de Infraestrutura

As estações de carregamento (EV) e de abastecimento (combustão) podem falhar:

- Probabilidade de Falha: 0.01% por tick de simulação
- Tempo de Recuperação: 120 minutos (2 horas)
- Impacto: Veículos precisam de desviar para estações alternativas, aumentando custos operacionais

Figura 4: Visualização de uma estação de serviço inoperacional

5.2. Agentes (Veículos)

A frota é heterogénea, composta por veículos com atributos distintos. A configuração padrão inclui:

ID	Estado	Bat.	Req.	Tipo	Pax	CO2(kg)	T.Abast	Ocup.Atual	Ocup.Média	⚠
EV-Smart	On Trip With Client	49/250	202	ELEC	3	0.00	51.0	67%	67%	0
EV-Sedan1	On Way To Client	294/300	205	ELEC	4	0.00	314.2	75%	65%	0
EV-Sedan2	At Station	167/350	---	ELEC	4	0.00	171.2	0%	79%	0
EV-Van1	At Station	105/380	---	ELEC	7	0.00	27.0	0%	58%	0
EV-Van2	At Station	269/420	---	ELEC	7	0.00	92.0	0%	54%	0
Gas-Compact	Available	74/600	---	COMB	3	18.24	0.0	0%	73%	0
Gas-Sedan1	On Way To Client	173/700	207	COMB	4	15.78	0.0	100%	71%	0
Gas-Sedan2	Available	179/750	---	COMB	4	15.42	0.0	0%	72%	0
Gas-Van1	On Trip With Client	370/800	206	COMB	7	4.75	0.0	86%	49%	0
Gas-Van2	Available	363/900	---	COMB	7	9.66	0.0	0%	56%	0

Figura 5: Gestão da Frota: Monitorização de estatísticas individuais

A frota é heterogénea, composta por veículos com atributos distintos. A tabela detalhada com as especificações técnicas de cada tipo de veículo (Combustão vs. Elétrico) encontra-se no Anexo B.

Os veículos elétricos destacam-se pelo baixo custo operacional (€0.04/km) mas requerem gestão cuidadosa de autonomia.

5.2.1. Gestão de Bateria/Combustível

O sistema implementa uma lógica de gestão preventiva:

- Limiar Crítico para Recarga: Quando a autonomia restante < 50 km, o veículo é automaticamente enviado para uma estação se não tiver nenhum pedido capaz de realizar.
- Penalização na Função de Custo: Quando a autonomia < 30 km, a função de custo aplica uma penalização quadrática: $P_{\text{bateria}} = W_{\text{bateria}} \times \left(\frac{30-\text{ autonomia}}{30}\right)^2$
- Tempo de Recarga:
  - **Veículos a combustão**: Reabastecimento fixo de 5 minutos.
  - **Veículos elétricos**: Recarga proporcional à taxa da estação.

5.3. Características dos Pedidos

Cada pedido de transporte é modelado como um agente com atributos que influenciam a atribuição e o custo.

5.3.1. Taxa de Chegada (Processo de Poisson)

A taxa de chegada $\lambda(t)$ varia ao longo do dia: $\lambda(t) = 0.2 + (\text{intensidade} \times 0.6)$

Período	Intensidade	Taxa (pedidos/min)
Madrugada (00:00-06:30)	0.1	0.26
Manhã (07:30-09:30)	0.7	0.62 (pico)
Almoço (12:00-14:00)	0.3	0.38
Tarde (17:00-19:30)	0.9	0.74 (pico máximo)
Pré-noite (19:30-21:00)	0.2	0.32
Noite (22:00-00:00)	0.1	0.26

Tabela 5: Taxa de Chegada de Pedidos por Período

Nota: Valores proporcionais à frota simulada (10 veículos). Padrões temporais baseados em dados do setor TVDE[1].

5.3.2. Atributos dos Pedidos

Cada pedido de transporte tem parâmetros diferentes sendo estes "aleatórios" na sua criação:

Atributo	**Descrição**
Prioridade (1-5)	VIP (5) tem 20% probabilidade em picos, 5% fora; 1-4 uniformes
Preço	$P = (2.50 + 0.80 \times D) \times M$, $M = 1.3$ se >4 passageiros, caso contratio $M = 1$
Preferência Ecológica	30% preferem veículos elétricos
Passageiros	1-4 (90%), 5-7 (10%)
Timeout	$T_{\max} = 30 - 5 \times (\text{Prio} - 1)$ minutos

Tabela 6: Detalhes dos Atributos dos Pedidos de Transporte

6. Algoritmos Desenvolvidos

6.1. Subproblema de Procura de Caminho

Considere-se o grafo da cidade de Braga, um nó de origem o (posição atual do veículo) e um nó de destino d (local de recolha do cliente). Este subproblema pode ser formulado do seguinte modo:

Tipo de problema: Procura de caminho num grafo com custos não-negativos.

Estado inicial: $E_0 = (o)$, posição atual do veículo.

Operador de mudança de estado: Seja n' um nó adjacente a n. O custo de viajar entre n e n' é dado por:

$$c_{n \to n'} = \frac{d(n, n')}{v} \times (1 + m(n, n'))$$

onde d calcula a distância (Haversine), v é a velocidade permitida na via, e m é o fator de trânsito.

Estado final: $E_f = (d)$, chegada ao destino.

Custo da solução: Soma dos tempos de viagem em cada aresta percorrida.

[1]IMT (2025). Plataforma IMT/Bolt/Uber.

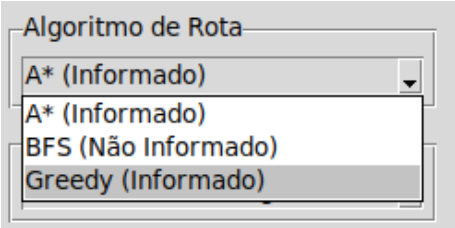

Figura 6: Seleção do algoritmo de procura de caminho

6.1.1. Algoritmos Implementados

Para resolver este subproblema, implementamos três algoritmos:

Algoritmo	Descrição	Tipo
BFS (Breadth-First Search)	Explora camada por camada. Garante menor número de "saltos".	Não Informada
Greedy	Escolhe sempre o nó com menor heurística $h(n)$.	Informada
A*	Minimiza $f(n) = g(n) + h(n)$. Garante caminho ótimo se h admissível.	Informada

Tabela 7: Algoritmos de Procura de Caminho Implementados

Heurística utilizada: Tempo de viagem em linha reta à velocidade máxima (120 km/h):

$$h(n) = \frac{\text{Haversine}(n, d)}{2} \text{ km/min}$$

Esta heurística é admissível porque nunca sobrestima o custo real — nenhum veículo pode viajar mais rápido que 120 km/h.

6.1.2. Comparação dos Algoritmos de Procura

Para comparar o desempenho e a qualidade das soluções, os algoritmos foram testados em 100 rotas aleatórias no grafo de Braga. Os resultados agregados são:

Algoritmo	Σ Tempo (ms)	Σ Custo (min)	Σ Nós Solução	Σ Nós Visitados
BFS	609.9	1482.5	4632	454619
Greedy	37.8	1637.1	7612	16179
A*	1631.8	1078.6	6478	327066

Tabela 8: Somas das Métricas de Procura (100 rotas de teste)

Análise dos Resultados:

- O **A*** encontra o caminho ótimo (menor custo: 1079 min, −27% vs. BFS) mas é o mais lento (1632ms) e visita muitos nós, demonstrando a exploração exaustiva necessária para garantir optimalidade.
- O **BFS** é mais rápido que o A* mas produz soluções subótimas (+37% custo) porque minimiza arestas, não tempo.
- O **Greedy** é o mais rápido (38ms) com poucos nós visitados, mas produz as piores soluções (+52% custo vs. A*) porque ignora o custo já percorrido.

6.2. Algoritmos de Atribuição (Assignment)

O problema de atribuir N veículos a M pedidos é combinatório. Implementamos três estratégias:

Algoritmo	Descrição	Limitação
Greedy	Faz a combinação mais barata imediata.	Ótimo local, não global
Hill Climbing	Tenta trocas a partir de solução inicial. Aceita se melhorar.	Fica preso em mínimos locais
Simulated Annealing	Aceita soluções piores com probabilidade $e^{-\Delta \frac{E}{T}}$ para escapar mínimos locais.	Mais lento, requer afinação

Tabela 9: Algoritmos de Atribuição Implementados

6.2.1. Simulated Annealing — Parâmetros

O Simulated Annealing foi escolhido como algoritmo principal devido à natureza combinatória do problema:

- **Temperatura Inicial** (T_0): 250.0 (aumenta para 450.0 quando há pedidos VIP)
- **Fator de Arrefecimento** (α): 0.95
- **Critério de Aceitação**: $P(\text{aceitar}) = e^{-\Delta \frac{E}{T}}$
- **Operadores de Vizinhança**: Assign, Unassign, Swap, Move, Replace

6.2.2. Justificação das Escolhas de Design

A escolha do Simulated Annealing como algoritmo principal de atribuição resultou de uma análise cuidadosa das características do problema:

1. Espaço de Estados Discreto e Combinatório: O problema de atribuir N veículos a M pedidos gera um espaço de $(M+1)^N$ estados possíveis (cada veículo pode estar livre ou atribuído a qualquer um dos M pedidos).

   Exemplo de cálculo para um caso (10 veículos, 20 pedidos pendentes):

   $$|S| = (20+1)^{10} = 21^{10} \approx 1.66 \times 10^{13}$$

   Se um computador avaliasse 1 milhão de estados por segundo, demoraria mais de 500 anos a explorar todas as combinações. Isto torna a procura exaustiva completamente impraticável, justificando o uso de Simulated Annealing.

2. A função de custo do nosso problema possui múltiplos mínimos locais devido às interações entre restrições (autonomia, capacidade, preferências ecológicas). Algoritmos puramente greedy ou hill climbing ficam facilmente presos nos mínimos locais.

3. Natureza Dinâmica do Problema: Como novos pedidos chegam continuamente e o estado dos veículos muda (bateria, posição), o algoritmo é re-executado frequentemente. O SA adapta-se bem a este contexto porque cada execução parte de uma solução inicial diferente (estado atual), beneficiando da exploração aleatória inicial.

4. Compromisso Tempo-Qualidade: O Simulated Annealing oferece soluções de alta qualidade em tempo previsível. O parâmetro de temperatura dinâmica ($T_0 = 250$ ou 450 para VIPs) permite ajustar automaticamente a exploração conforme a urgência.

5. Alternativas Consideradas:
    - **Algoritmo Húngaro**: Ótimo mas $O(n^3)$ e não lida bem com restrições complexas (autonomia, preferências).
    - **Programação Linear Inteira**: Garantia de optimalidade mas demasiado lento para decisões em tempo real.

6.3. Otimização da Atribuição de Pedidos

A função `assign_pending_requests` é o componente central do sistema de decisão. O processo implementa várias otimizações para garantir eficiência em tempo real.

6.3.1. Pipeline de Atribuição

1. Recolha de Candidatos: Identifica veículos disponíveis e redirecionáveis (já a caminho de um cliente, mas que podem mudar de destino).
2. Construção da Matriz de Custos ($N \times M$): Cada célula $C[i, j]$ representa o custo de atribuir o veículo i ao pedido j, calculado via `calculate_detailed_cost`.
3. Aplicação de Filtros (Pruning): Atribuições impossíveis recebem custo ∞:
    - Capacidade insuficiente para passageiros
    - Autonomia insuficiente para completar a viagem
    - Impossibilidade de chegar a um posto após a entrega
4. Resolução via Meta-Heurística: O Simulated Annealing encontra a configuração que minimiza a energia total.
5. Execução e Reatribuição: Aplica as decisões, libertando veículos de tarefas anteriores se necessário.

6.3.2. Otimizações Implementadas

Otimização	Descrição
Estimativa Heurística	Na construção da matriz de custos, usamos distância de Haversine em vez de A* completo. Reduz o tempo de $O(A \log V)$ (A = Arestas, V = Vertices) para $O(1)$ por par veículo-pedido. O A* real é usado apenas na rota final.
Cache de Trânsito	O `TrafficManager` mantém cache espacial de penalizações de trânsito, limpa a cada tick. Evita recalcular ruído de Perlin para posições próximas.
Cache de Hotspots	Cada hotspot pré-calcula os nós próximos (`node_cache`) na inicialização. Acelera a seleção de origens/destinos.
Redirecionamento Dinâmico	Veículos em estado `ON_WAY_TO_CLIENT` são incluídos na reavaliação. Permite trocar atribuições se surgir um pedido mais urgente.
Temperatura Adaptativa	A temperatura inicial do SA aumenta de 250 para 450 quando há pedidos VIP (prioridade ≥ 4) ou fila de espera saturada.
Bónus de Estabilidade	Manter a mesma atribuição dá um bónus de −5.0 no custo, evitando oscilações constantes (*jitter*) entre soluções equivalentes.

Tabela 10: Otimizações Implementadas no Sistema de Atribuição

A função de custo utilizada para preencher a matriz é detalhada na Tabela 4.

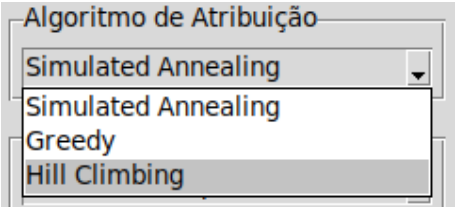

Figura 7: Seleção do algoritmo de atribuições

7. Reprodutibilidade e Determinismo

A simulação produz resultados idênticos em cada execução, graças ao uso de seeds fixas em todos os processos estocásticos.

7.1. Componentes com Seed Fixa

Componente	Seed	O que controla
Gerador de Pedidos	12345	Intervalos, origens/destinos, prioridades, preferências
Criação da Frota	42	Posições iniciais dos 10 veículos
Trânsito (Perlin)	42	Padrões espaciais de congestionamento
Meteorologia (Perlin)	42	Transições de clima (Sol/Chuva/Tempestade)
Falhas de Estações	42	Quando e quais estações falham (0.01%/tick)

Tabela 11: Seeds Fixas para Reprodutibilidade

7.2. Processos Estocásticos

Geração de Pedidos (Processo de Poisson Não-Homogéneo):

- A taxa de chegada $\lambda(t)$ varia ao longo do dia para simular picos de procura.
- O intervalo até ao próximo pedido é dado por: $\Delta t = -\frac{\ln(U)}{\lambda(t)}$, onde $U \in (0, 1]$.
- Isto cria intervalos menores entre pedidos quando $\lambda(t)$ é alto (horas de ponta).

Seleção de Hotspots:

- Origens e destinos são selecionados com base nos pesos dos hotspots ativos.

Trânsito e Meteorologia:

- Ruído de Perlin 3D para variação espacial/temporal do tráfego.
- Ruído de Perlin 1D para transições suaves de clima.

Falhas de Infraestrutura:

- Cada estação tem 0.01% de probabilidade de falhar por tick de simulação.

7.3. Exceção

O **Simulated Annealing** usa `random.random()` global — intencional para explorar diferentes caminhos no espaço de soluções, enquanto o workload permanece idêntico.

8. Metodologia de Testes e Resultados

8.1. Configuração Experimental

Para avaliar a eficiência dos algoritmos utilizámos um sistema de benchmark automatizado que executa simulações paralelas via `ProcessPoolExecutor`. Cada configuração foi testada durante 28 dias simulados (672 horas) com condições iguais, garantidas pelo uso de seeds fixas.

Parâmetro	Valor
Duração Simulada	672 horas
Frota	10 veículos (5 EV + 5 combustão)
Total de Pedidos	≈14 090
Combinações Testadas	9 (3 routing × 3 assignment)
Tempo Real de Execução	3 759s (BFS) a 9 114s (A* + SA)

Tabela 12: Configuração do Ambiente de Benchmark

8.2. Métricas de Avaliação

As métricas recolhidas dividem-se em três categorias, alinhadas com os objetivos do enunciado:

Categoria	Métrica	Unidade
Financeira	Receita Total / Custo Total / Lucro Líquido	€
Operacional	Pedidos Completos / Falhados (Taxa de Sucesso)	contagem / %
Operacional	Tempo Médio de Espera (resposta ao pedido)	minutos
Operacional	Tempo Médio de Viagem	minutos
Operacional	Km Totais / Vazios / Ocupados	km
Operacional	Taxa de Ocupação (geral, EV, combustão)	%
Ambiental	Emissões Totais de CO2	kg
Ambiental	Rácio de Km por EVs	%

Tabela 13: Métricas Recolhidas por Cada Simulação

8.3. Resultados Globais

A tabela seguinte resume os resultados das 9 combinações testadas, ordenadas por algoritmo de routing:

Routing	Assignment	Lucro (€)	Completos	Taxa (%)	Espera (min)	Km Vazios	CO2 (kg)
BFS	Greedy	76 272	11 183	79.4	15.87	70 960	6 600
BFS	Hill Climbing	76 305	11 586	82.2	14.01	69 145	6 313
BFS	Sim. Annealing	76 070	11 569	82.1	14.07	69 453	6 314
Greedy	Greedy	76 688	11 197	79.5	16.55	67 254	6 420
Greedy	Hill Climbing	76 415	11 531	81.8	14.68	64 997	6 132
Greedy	Sim. Annealing	75 566	11 421	81.1	14.50	64 851	6 086
A*	Greedy	**79 629**	11 613	82.4	13.22	66 524	6 392
A*	Hill Climbing	79 331	**11 921**	**84.6**	11.82	64 540	6 121
A*	Sim. Annealing	79 349	**11 921**	**84.6**	**11.72**	**63 937**	**6 029**

Tabela 14: Resultados das 9 Combinações de Algoritmos

Legenda: A coluna Taxa (%) indica a percentagem de pedidos atendidos com sucesso. Os valores destacados (**negrito**) representam os melhores resultados em cada métrica.

8.4. Análise Detalhada

8.4.1. Impacto do Algoritmo de Routing

O algoritmo de routing (procura de caminho) tem impacto significativo no desempenho global:

Routing	Receita Média (€)	Custo Médio (€)	Lucro Médio (€)
BFS	88 223	11 997	76 216
Greedy	87 644	11 421	76 223
A*	**90 336**	**11 094**	**79 436**

Tabela 15: Métricas Financeiras por Algoritmo de Routing

O A* supera as alternativas: gera +€2 100/mês de receita face ao BFS enquanto reduz custos operacionais em €900/mês, resultando num lucro 4.2% superior.

8.4.2. Impacto do Algoritmo de Atribuição

Para isolar o efeito dos algoritmos de atribuição, fixamos o routing em A*:

Assignment	Completos	Espera (min)	Km Vazios	CO2 (kg)	Lucro (€)
Greedy	11 613	13.22	66 524	6 392	**79 629**
Hill Climbing	**11 921**	11.82	64 540	6 121	79 331
Simulated Annealing	**11 921**	**11.72**	**63 937**	**6 029**	79 349

Tabela 16: Comparação dos Algoritmos de Atribuição

Observações:

- O Greedy maximiza o lucro (+€280) mas sacrifica a qualidade de serviço: 308 pedidos a menos e 1.5 min de espera adicional
- O Hill Climbing e Simulated Annealing obtêm resultados quase idênticos, sugerindo que a função de custo tem poucos mínimos locais
- O SA tem ligeira vantagem em CO2 (−92 kg) e tempo de espera (−0.1 min)

8.4.3. Tempo Médio de Resposta ao Pedido

O tempo de espera mede o intervalo desde a criação do pedido até à chegada do veículo:

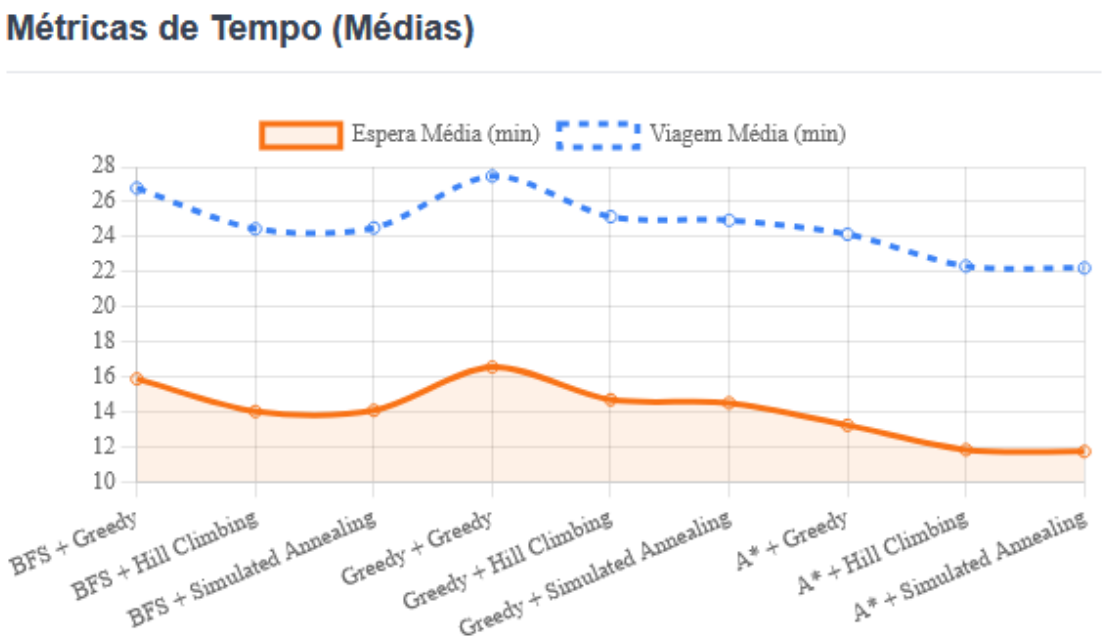

Figura 8: Gráfico de métricas temporais: Espera vs. Viagem

- Pior cenário: Greedy + Greedy → 16.55 min (atribuições imediatas sem otimização)
- Melhor cenário: A* + SA → 11.72 min (−29%)

8.4.4. Taxa de Pedidos Não Atendidos

Um pedido falha quando expira por timeout antes de ser atendido:

Combinação	Completos	Falhados	Taxa Sucesso
BFS + Greedy	11 183	2 907	79.4%
Greedy + Greedy	11 197	2 893	79.5%
A* + Greedy	11 613	2 477	82.4%
A* + SA	**11 921**	**2 168**	**84.6%**

Tabela 17: Taxa de Sucesso (Pedidos Atendidos)

A combinação A* + SA atende 738 pedidos adicionais (+6.6%) face ao pior cenário.

8.4.5. Emissões de CO2

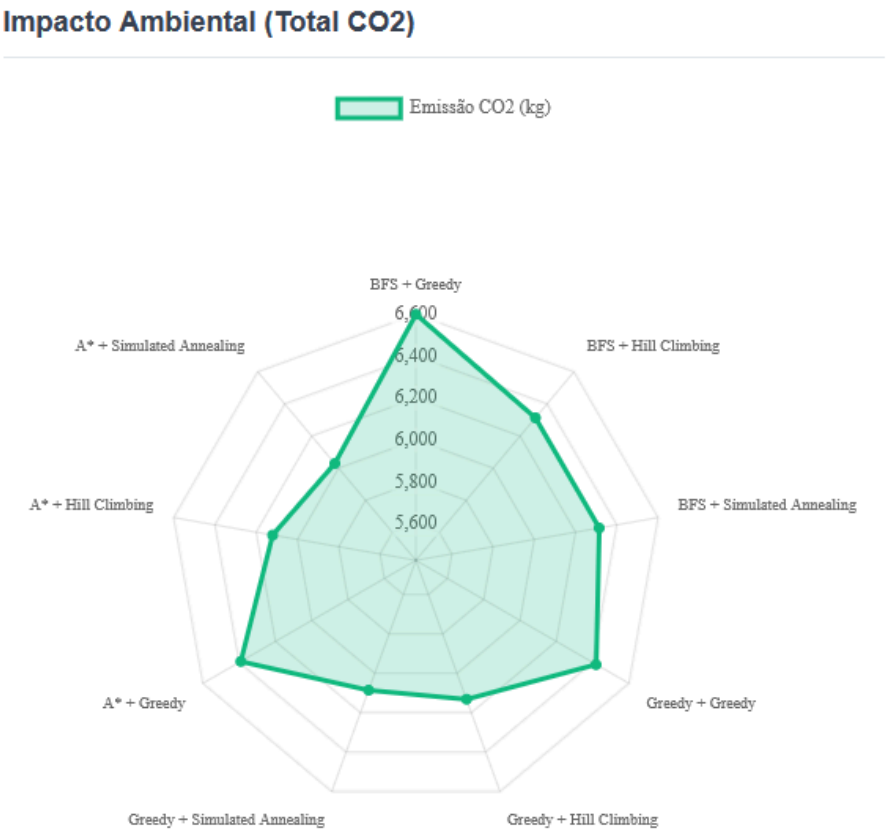

Figura 9: Análise do Impacto Ambiental (Emissões CO2)

A combinação A* + SA emitiu apenas 6 029 kg de CO2 (−571 kg / −8.6% em relação a BFS + Greedy), graças a:

- Maior utilização de EVs (49.3% dos km vs. 47.0%)
- Menos km percorridos em vazio

8.4.6. Taxa de Ocupação da Frota

A ocupação mede a proporção de km em que os veículos transportam passageiros:

Combinação	Geral	EV	Combustão
BFS + Greedy	50.4%	49.5%	51.3%
Greedy + SA	51.9%	51.2%	52.5%
A* + Greedy	52.9%	52.1%	53.6%
A* + SA	**53.3%**	**52.1%**	**54.4%**

Tabela 18: Taxa de Ocupação da Frota

Veículos a combustão têm ocupação ligeiramente superior (+2%) devido à maior autonomia.

8.4.7. Km Percorridos Sem Passageiros

Os km vazios (deslocações para recolha e desvios a estações) impactam custos e emissões:

Routing	Assignment	Km Total	Km Vazios	Rácio
BFS	Greedy	143 205	70 960	49.6%
BFS	Hill Climbing	139 900	69 145	49.4%
BFS	Sim. Annealing	140 017	69 453	49.6%
Greedy	Greedy	139 610	67 254	48.2%
Greedy	Hill Climbing	135 637	64 997	47.9%
Greedy	Sim. Annealing	**134 718**	64 851	48.1%
A*	Greedy	141 138	66 524	47.1%
A*	Hill Climbing	137 493	64 540	46.9%
A*	SA	136 790	**63 937**	**46.7%**

Tabela 19: Km Percorridos Sem Passageiros

O A* + SA reduziu os km vazios em 7 023 km (−10%) face ao BFS + Greedy.

8.5. Síntese dos Resultados

Objetivo	Melhor Combinação	Valor
Maior Lucro	A* + Greedy	€79 629
Menor Tempo de Espera	A* + Simulated Annealing	11.72 min
Menor CO2	A* + Simulated Annealing	6 029 kg
Maior Taxa de Sucesso	A* + Simulated Annealing	84.6%
Menor Km Vazios	A* + Simulated Annealing	63 937 km

Tabela 20: Resumo: Melhor Combinação por Objetivo

A análise indica que A* + Simulated Annealing é a estratégia ideal para a TaxiGreen, oferecendo o melhor equilíbrio entre:

1. Qualidade de serviço (−29% tempo de espera)
2. Sustentabilidade ambiental (−8.6% CO2)
3. Eficiência operacional (−10% km vazios)
4. Viabilidade financeira (99.6% do lucro máximo)

Esta solução demonstra que é possível ser sustentável sem comprometer a rentabilidade.

9. Correspondência com as Tarefas Pedidas

Esta secção mapeia cada tarefa solicitada no enunciado à nossa implementação:

Tarefa	Implementação
Formular o problema como procura	✓ Definido como Otimização Combinatória Dinâmica com estado $S_t = (A, B, V)$, operadores (Assign, Swap, Move, etc.), e função de energia
Representar cidade como grafo	✓ Grafo real de Braga via OSMnx, nós=intersecções, arestas=estradas com distâncias Haversine
Desenvolver estratégias informadas e não informadas	✓ Implementados BFS (não informada), Greedy, A* (informadas).
Implementar sistema de simulação dinâmica	✓ Simulador com chegadas de pedidos via Processo de Poisson, trânsito dinâmico (Perlin + Gaussianas), meteorologia, falhas de infraestrutura
Avaliar eficiência com métricas	✓ Benchmark com 9 combinações de algoritmos, métricas: Lucro, Taxa de Ocupação, Tempo de Espera, km Vazios, CO2
Simular condições dinâmicas	✓ Trânsito variável (picos de hora), meteorologia (Sol/Nevoeiro/Chuva/Tempestade), falhas de estações

Tabela 21: Correspondência Tarefa-Implementação

9.1. Funcionalidades Extra Implementadas

Além dos requisitos base, implementámos:

1. Hotspots Geográficos: Sistema de zonas de alta densidade com horários de funcionamento e peso na criação de pedidos.
2. Gestão Preventiva de Bateria: Penalização quadrática para baixa autonomia.
3. Sistema de Prioridade Escalonado: Timeouts diferentes por prioridade.
4. Trânsito e meteorologia Dinâmica: Curvas Gaussianas e Ruído de Perlin.
5. Benchmark Automatizado: Sistema de testes concorrentes (`ProcessPoolExecutor`) para comparar 9 configurações de algoritmos em 28 dias simulados.
6. Reprodutibilidade: Seeds fixas garantem que benchmarks são justos e replicáveis.

10. Conclusão e Reflexão

O projeto atingiu o objetivo principal de desenvolver um sistema inteligente de gestão de frota para a TaxiGreen, capaz de operar num ambiente urbano dinâmico e complexo. A solução implementada equilibra eficazmente os custos operacionais, a satisfação do cliente (tempo de espera) e a sustentabilidade ambiental, respondendo aos desafios da mobilidade moderna.

Os resultados do benchmark demonstraram que a combinação de A* (para navegação) e Simulated Annealing (para atribuição) superou as outras abordagens. O A* garantiu rotas ótimas que reduziram os quilómetros percorridos em vazio, enquanto o Simulated Annealing permitiu uma gestão global da frota, evitando mínimos locais e priorizando veículos elétricos sempre que viável, resultando numa redução de 8.6% nas emissões de CO2.

10.1. Resposta aos Desafios do Enunciado

O sistema lidou com sucesso com as restrições impostas:

- Gestão de Frota Mista: A lógica de custo penalizou o uso de veículos a combustão para pedidos "eco" e garantiu que os EVs fossem carregados preventivamente.
- Dinamismo: O planeamento contínuo permitiu reagir a novos pedidos, trânsito variável e falhas de infraestrutura em tempo real.
- Equilíbrio de Objetivos: A função de custo multiobjetivo permitiu afinar o peso do lucro vs. serviço ao cliente.

11. Apresentação da Interface

A aplicação desenvolvida disponibiliza uma interface gráfica que permite visualizar e controlar a simulação em tempo real.

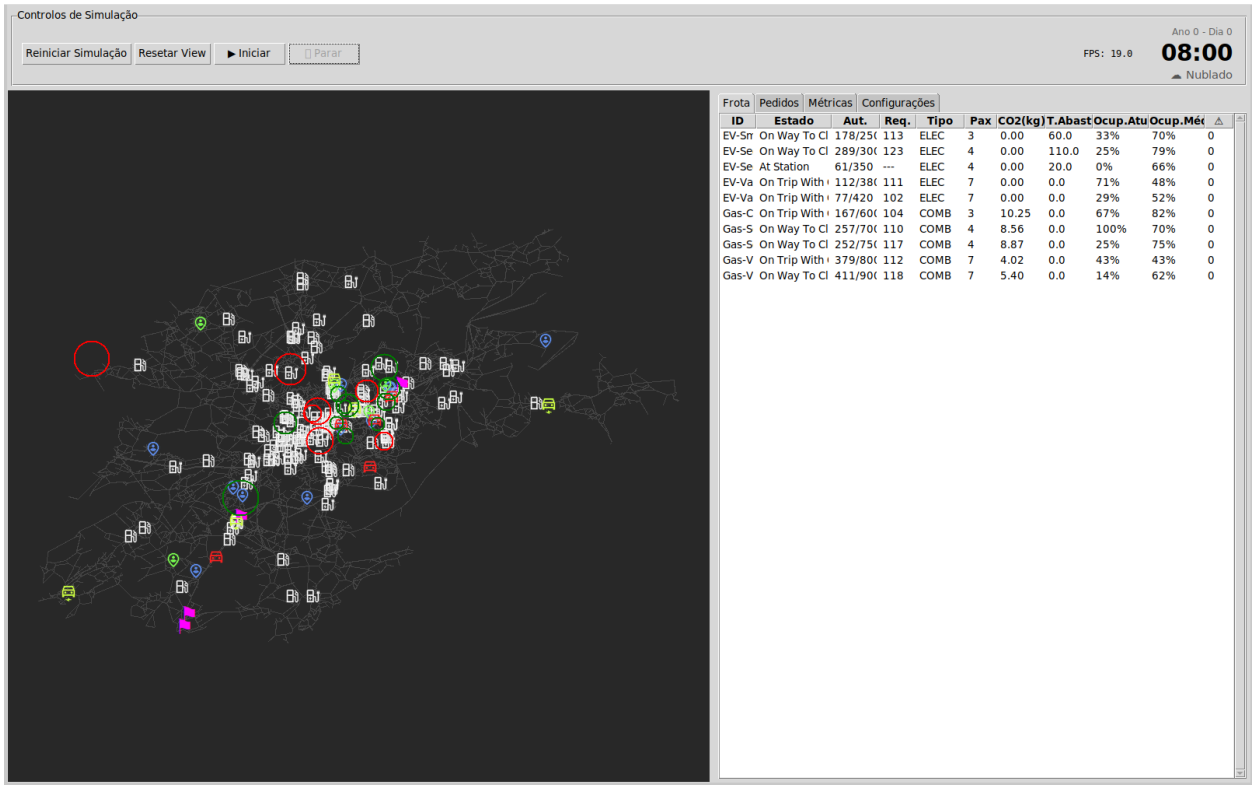

Figura 10: Visualização do mapa com veículos e pedidos em tempo real e Painel lateral com métricas de desempenho (lucro, CO2, tempos de espera)

A interface permite:

- **Zoom e Navegação**: Scroll para zoom, arrastar para mover o mapa
- **Visualização de Trânsito**: Arestas coloridas (verde→vermelho) indicam congestionamento
- **Hotspots**: Círculos verdes/vermelhos mostram zonas de alta procura ativas/inativas
- **Estados dos Veículos**: Ícones diferentes para EVs e veículos a combustão
- **Métricas**: Painel para observar valores da simulação
- **Configuração**: Painel para alterar algoritmos de routing/assignment em tempo real

12. Referências

[1] Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.

[2] Boeing, G. (2017). “OSMnx: New Methods for Acquiring, Constructing, Analyzing, and Visualizing Complex Street Networks”. *Computers, Environment and Urban Systems*, 65, 126-139.

[3] Instituto da Mobilidade e dos Transportes (2025). *Estatísticas TVDE Portugal*. Plataforma IMT.

[4] Associação Automóvel de Portugal (2024). *Emissões médias de CO2 em Portugal*. Revista ACP.

Anexos

12.1. Anexo A: Galeria da Interface

Nesta secção apresentamos capturas de ecrã adicionais que ilustram a interface gráfica desenvolvida para monitorização e controlo da simulação.

12.1.1. Controlos e Ambiente

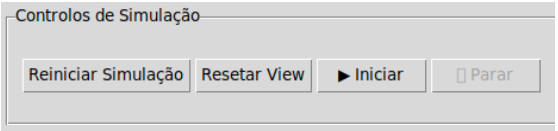

Figura 11: Painel de Controlo da Simulação

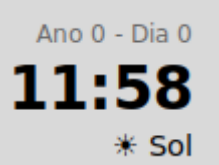

Figura 12: Ciclo Dia/Noite na Interface

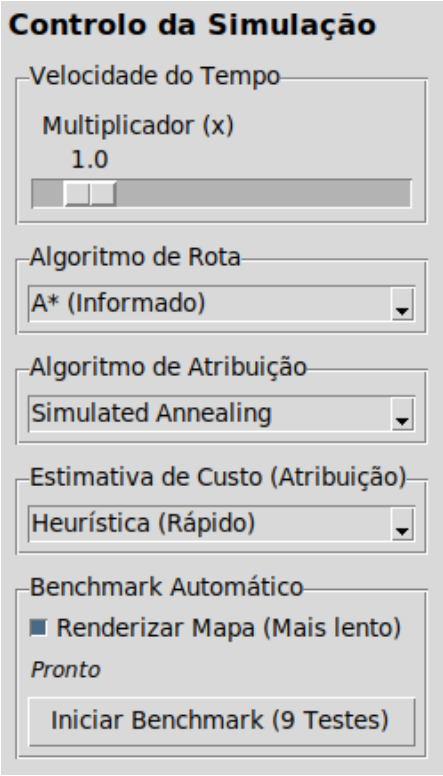

Figura 13: Painel de Controlos dos algoritmos, velocidade de simulação e benchmark

12.1.2. Gestão de Pedidos

ID	Estado	Origem	Destino	Pax	Eco
202	Viagem	(-8.4883424, 41.5678246)	(-8.4206995, 41.5546281)	2	Sim
205	Apanhar	(-8.496704, 41.564346)	(-8.4265626, 41.5528703)	3	-
206	Viagem	(-8.4004705, 41.5747995)	(-8.4285426, 41.5496324)	6	-
207	Apanhar	(-8.4484609, 41.5721232)	(-8.4025038, 41.5650716)	4	-

Figura 14: Lista de Pedidos Ativos

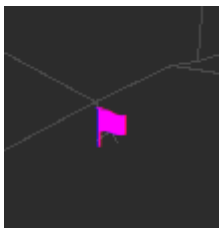

Figura 15: Visualização de Destino no Mapa

Figura 16: Pedido Pendente (Azul)

Figura 17: Pedido Atribuído (Verde)

12.1.3. Infraestrutura e Veículos

Figura 18: Posto de Abastecimento

Figura 19: Posto de Carregamento EV

Figura 20: Posto de Abastecimento e Carregamento EV

12.1.4. Visualização de Dados

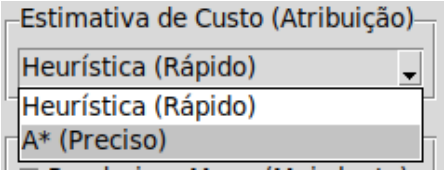

Figura 21: Visualização do Processo de Otimização

Em Tempo Real (Snapshot)

Custo Op. Instantâneo:	€0.17
Receita Instantânea:	€0.00
Pendentes na Fila:	0
Veículos Ativos:	7

Desempenho Financeiro

Receita Total:	€1,131.47
Custo Op. Total:	€125.22
Lucro Líquido:	€1,006.25

Eficiência Operacional

Pedidos (Ok/Fail):	157 / 46
Cancelados (Timeout):	46
Km Vazios (%):	44.0%
Km Vazios EV (%):	44.7%
Km Vazios Gas (%):	43.2%
Emissões CO2:	63.85 kg
Perda Tempo (EV vs Gas):	655.4m vs 0.0m

Tempo de Serviço (Minutos)

Espera Média (Recolha):	11.8 min
Espera [Mín - Máx]:	1.1 - 35.2
Viagem Média (Entrega):	23.0 min
Viagem [Mín - Máx]:	3.2 - 62.4

Figura 22: Painel de Métricas em Tempo Real

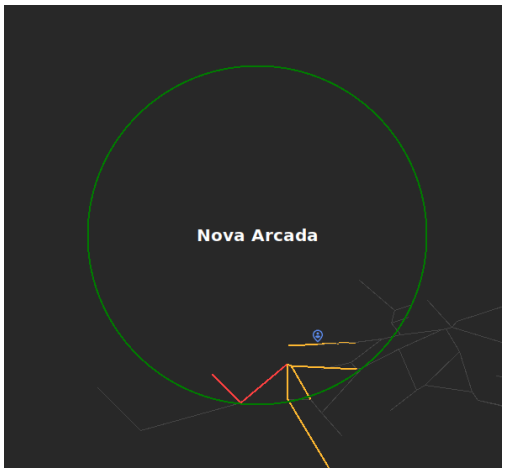

Figura 23: Hotspot Ativo (Alta Procura)

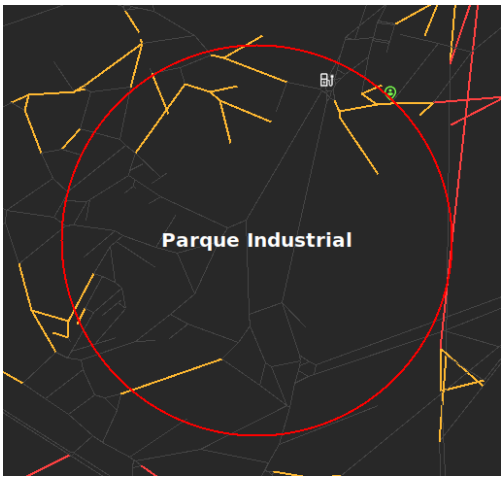

Figura 24: Hotspot Inativo

12.2. Anexo B: Especificações da Frota

Característica	Combustão (Gas)	Elétrico (EV)
Quantidade	5 veículos	5 veículos
Autonomia	600-900 km	200-420 km
Tempo de Recarga	5 minutos	Lento: 45-60 min Rápido: 20-30 min
Custo Operacional	€0.12/km	€0.04/km
Emissões CO_2[2]	87g/km	0g/km (local)
Vantagens	Alta autonomia, reabastecimento rápido	Custo reduzido, zero emissões locais
Desvantagens	Custo elevado, poluente	Autonomia limitada, recarga demorada

Tabela 22: Comparação detalhada entre Tipos de Veículos

12.3. Anexo C: Dados Completos de Benchmark

Esta secção apresenta todos os dados recolhidos durante os testes de benchmark (28 dias simulados, 672 horas). Os valores foram extraídos diretamente dos ficheiros JSON gerados pelo sistema.

[2] Fonte: ACP Portugal, média nacional 2024

12.3.1. Métricas Financeiras

Routing	Assignment	Receita (€)	Custo (€)	Lucro (€)	Tempo De Simulação
BFS	Greedy	88 538	12 266	76 272	3 759
BFS	Hill Climbing	88 159	11 854	76 305	3 762
BFS	Sim. Annealing	87 934	11 864	76 070	3 859
Greedy	Greedy	88 632	11 944	76 688	1 248
Greedy	Hill Climbing	87 922	11 507	76 415	1 275
Greedy	Sim. Annealing	86 986	11 420	75 566	1 337
A*	Greedy	**91 565**	11 936	**79 629**	9 153
A*	Hill Climbing	90 854	11 523	79 331	9 022
A*	Sim. Annealing	90 753	**11 404**	79 349	9 114

Tabela 23: Benchmark — Métricas Financeiras Completas

12.3.2. Métricas Operacionais

Routing	Assignment	Finalizados	Falhados	Espera Média	Tempo de Viagem
BFS	Greedy	11 183	2 907	15.87	26.78
BFS	Hill Climbing	11 586	2 504	14.01	24.45
BFS	Sim. Annealing	11 569	2 521	14.07	24.51
Greedy	Greedy	11 197	2 893	16.55	27.46
Greedy	Hill Climbing	11 531	2 559	14.68	25.15
Greedy	Sim. Annealing	11 421	2 668	14.50	24.94
A*	Greedy	11 613	2 477	13.22	24.14
A*	Hill Climbing	**11 921**	2 169	11.82	22.32
A*	Sim. Annealing	**11 921**	**2 168**	**11.72**	**22.21**

Tabela 24: Benchmark — Métricas Operacionais Completas

12.3.3. Métricas de Quilometragem

Routing	Assignment	Km Total	Km Vazios	Km Ocupados	Ocupação (%)
BFS	Greedy	143 205	70 960	72 244	50.4
BFS	Hill Climbing	139 900	69 145	70 755	50.6
BFS	Sim. Annealing	140 017	69 453	70 564	50.4
Greedy	Greedy	139 610	67 254	72 356	51.8
Greedy	Hill Climbing	135 637	64 997	70 640	52.1
Greedy	Sim. Annealing	134 718	64 851	69 867	51.9
A*	Greedy	141 138	66 524	**74 614**	52.9
A*	Hill Climbing	137 493	64 540	72 952	53.1
A*	Sim. Annealing	136 790	**63 937**	72 853	**53.3**

Tabela 25: Benchmark — Métricas de Quilometragem Completas

12.3.4. Métricas Ambientais e de Frota

Routing	Assignment	CO2 (kg)	EV Ratio (%)	Ocupação EV (%)	Ocupação Gas (%)
BFS	Greedy	6 600	47.0	49.5	51.3
BFS	Hill Climbing	6 313	48.1	49.5	51.6
BFS	Sim. Annealing	6 314	48.2	49.4	51.3
Greedy	Greedy	6 420	47.1	50.9	52.7
Greedy	Hill Climbing	6 132	48.0	51.1	52.9
Greedy	Sim. Annealing	6 086	48.1	51.2	52.5
A*	Greedy	6 392	47.9	**52.1**	53.6
A*	Hill Climbing	6 121	48.8	52.0	54.1
A*	Sim. Annealing	**6 029**	**49.3**	**52.1**	**54.4**

Tabela 26: Benchmark — Métricas Ambientais e de Frota

12.3.5. Tempo em Estações de Recarga

Routing	Assignment	Tempo EV (min)	Tempo Gas (min)
BFS	Greedy	41 361	550
BFS	Hill Climbing	39 198	525
BFS	Sim. Annealing	39 828	525
Greedy	Greedy	38 170	535
Greedy	Hill Climbing	**36 512**	510
Greedy	Sim. Annealing	37 486	**505**
A*	Greedy	39 820	535
A*	Hill Climbing	38 598	515
A*	Sim. Annealing	37 604	510

Tabela 27: Benchmark — Tempo Total em Estações de Recarga/Abastecimento

Nota: Os dados foram recolhidos com seeds fixas para garantir reprodutibilidade. Os ficheiros JSON originais encontram-se na pasta `benchmark_results/` do projeto.